UNIVERSIDADE FEDERAL DE SERGIPE
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

- **Disciplina:**
  Tópicos Avançados em Engenharia de Software e Sistemas de Informação
- **Professor:**
  Dr. Glauco de Figueiredo Carneiro
- **Aluno:**
  Paulo do Amaral Costa **(Equipe 4)**
- **Data:**
  09/04/2026

RELATÓRIO ATIVIDADE -1

Link Repositório Github e Link Vídeo Apresentação

Repositório
https://github.com/pamaralifs/atividade1_taessi/tree/main/files

Site Relatório (Github Pages)
https://pamaralifs.github.io/atividade1_taessi/#visualizadores

Vídeo Paulo_equipe_04_apresentacao_09-04-2026_02-23
https://www.vidline.com/share/V02WHO34G6/a1f63c7d913ddae74c079450eba8ac35

Avaliação comparativa de 3 LLMs com questões da OAB

Modelos avaliados: **3** (jurema:7b · gemma3:12b · llama3.1:8b)
Questões abertas: **10** (60 registros consolidados)
Questões objetivas: **123** (369 registros consolidados)

Metodologia

Dataset e Curadoria

Questões abertas

- O dataset de 10 questões foi curado por "Área de especialidade", "Nível de dificuldade" e "Legislação de referência".
- BERTScore F1 foi a métrica algorítmica usada para avaliar as respostas dos modelos, com os modelos BERTimbau Large (brasileiro) e mBERT (multilingual) usados na vetorização dos textos em português.
- O BERTimbau ou mBERT vetoriza o texto e o algoritmo BERTScore calcula a similaridade similaridade do cosseno, comparando semânticamente as respostas dos modelos com as "respostas de referência" do gabarito espelho da prova do 42º Exame da OAB.

Questões objetivas

- O dataset de 123 questões foi curado por "Área de especialidade" e "Nível de dificuldade".
- Acurácia sobre a alternativa correta foi a métrica usada para avaliar as respostas dos modelos.

Ambiente dos Experimentos

Plano Experimental

- Os experimentos foram realizados no ambiente do Google Colab, com a GPU NVIDIA T4 de 16 GB de VRAM.
- As submissões das questões aos LLMs foram executadas via interface API do Ollama (api/chat), através de script Python.
- Os modelos foram executados 100% em GPU:

Parâmetros de Execução:

- PARAMETER temperature 0 (objetividade e precisão).
- PARAMETER repeat_penalty 1.2 (penalidade de repetição).
- PARAMETER repeat_last_n 128 (janela de observação de repetição).

- PARAMETER num_predict 512 (limitar tokens para evitar respostas infinitas).
- Não foi preciso definir o PARAMETER num_ctx (janela de contexto), principalmente para questões objetivas, a fim de poder capturar respostas de modelos pensantes, sendo adotado o padrão do Ollama (2048 tokens).
- Iguais para questões abertas e objetivas

Modelos e Softwares

LLMs avaliados

- jurema:7b
  LLM jurídico brasileiro de código aberto (sob licença Apache 2.0), treinado com dados nacionais e criado por Escavador e NeuralMind.
- llama3.1:8b
  LLM multilíngue de pesos abertos, criado pela Meta.
- gemma3:12b
  LLM multilíngue de pesos abertos da Google, construída com a tecnologia Gemini.

Ferramentas de Software

- Ollama versão 0.20.3 (ferramenta para execução local de LLMs)
- Python versão 3.12.13 (scripts para submissão, cálculo das métricas, criação de tabelas, gráficos e outros arquivos de saída.)
- Visual Studio Code (edição de scripts Python e arquivos JSON)
- Microsoft Excel e Bloco de Notas (edição e visualização de arquivos CSV.)

Resultado Questões Abertas

Foram 10 questões abertas do 42º Exame da OAB 2024/2025, sendo 5 de Direito Constitucional e 5 de Direito do Trabalho. O conjunto inclui 2 peças profissionais e 8 questões discursivas com itens A e B. Abaixo encontram-se as tabelas e gráficos dos resultados.

Melhor modelo (BERTimbau)

llama3.1:8b

F1-Score: 64.5%

Avaliadores usados

2

BERTimbau Large e mBERT

Questões analisadas

10

2 peças profissionais + 8 questões com itens A e B

Tabelas - Questões Abertas

Ranking final - BERTScore (BERTimbau)

Modelo	Quantidade Questões	F1-Score (%)
llama3.1:8b	10	64.5
gemma3:12b	10	63.6
jurema:7b	10	61.8

Resumo por modelo e avaliador

Modelo	Modelo BERTScore	Quantidade Questões	F1-Score (%)
llama3.1:8b	BERTimbau_Large	10	64.5
gemma3:12b	BERTimbau_Large	10	63.6
jurema:7b	BERTimbau_Large	10	61.8
llama3.1:8b	mBERT	10	62.5
gemma3:12b	mBERT	10	59.4
jurema:7b	mBERT	10	57.6

Por área de especialidade

Modelo	Modelo BERTScore	Área Especialidade	Quantidade Questões	F1-Score (%)
gemma3:12b	BERTimbau_Large	Direito do Trabalho	5	64.1
gemma3:12b	BERTimbau_Large	Direito Constitucional	5	63.2
gemma3:12b	mBERT	Direito do Trabalho	5	59.5
gemma3:12b	mBERT	Direito Constitucional	5	59.3
jurema:7b	BERTimbau_Large	Direito do Trabalho	5	62.9
jurema:7b	BERTimbau_Large	Direito Constitucional	5	60.8
jurema:7b	mBERT	Direito do Trabalho	5	57.7
jurema:7b	mBERT	Direito Constitucional	5	57.6
llama3.1:8b	BERTimbau_Large	Direito Constitucional	5	64.5
llama3.1:8b	BERTimbau_Large	Direito do Trabalho	5	64.5
llama3.1:8b	mBERT	Direito Constitucional	5	63.6
llama3.1:8b	mBERT	Direito do Trabalho	5	61.4

Por nível de dificuldade

Modelo	Modelo BERTScore	Nível Dificuldade	Quantidade Questões	F1-Score (%)
gemma3:12b	BERTimbau_Large	Médio	6	64.4
gemma3:12b	BERTimbau_Large	Difícil	4	62.4
gemma3:12b	mBERT	Difícil	4	61.1
gemma3:12b	mBERT	Médio	6	58.2
jurema:7b	BERTimbau_Large	Médio	6	62
jurema:7b	BERTimbau_Large	Difícil	4	61.5
jurema:7b	mBERT	Difícil	4	59.9
jurema:7b	mBERT	Médio	6	56.1
llama3.1:8b	BERTimbau_Large	Difícil	4	64.9
llama3.1:8b	BERTimbau_Large	Médio	6	64.2
llama3.1:8b	mBERT	Difícil	4	63.2
llama3.1:8b	mBERT	Médio	6	62

Por tipo de questão

Modelo	Modelo BERTScore	Tipo Questão Discursiva	Quantidade Questões	F1-Score (%)
gemma3:12b	BERTimbau_Large	2 itens (A e B)	8	63.9
gemma3:12b	BERTimbau_Large	1 item (Peça profissional)	2	62.8
gemma3:12b	mBERT	1 item (Peça profissional)	2	65.4
gemma3:12b	mBERT	2 itens (A e B)	8	57.9
jurema:7b	BERTimbau_Large	1 item (Peça profissional)	2	63
jurema:7b	BERTimbau_Large	2 itens (A e B)	8	61.5
jurema:7b	mBERT	1 item (Peça profissional)	2	65.7
jurema:7b	mBERT	2 itens (A e B)	8	55.6
llama3.1:8b	BERTimbau_Large	1 item (Peça profissional)	2	66.9
llama3.1:8b	BERTimbau_Large	2 itens (A e B)	8	63.9
llama3.1:8b	mBERT	1 item (Peça profissional)	2	69.6
llama3.1:8b	mBERT	2 itens (A e B)	8	60.7

Gráficos - Questões abertas

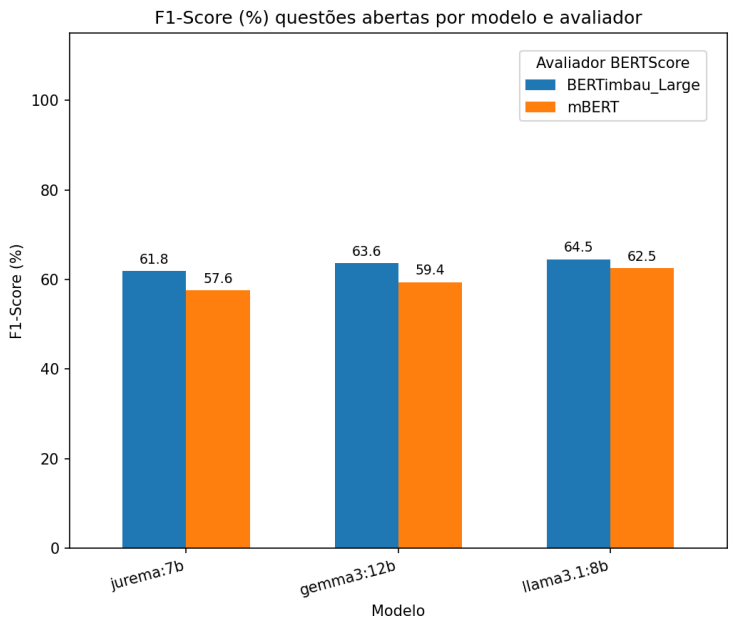

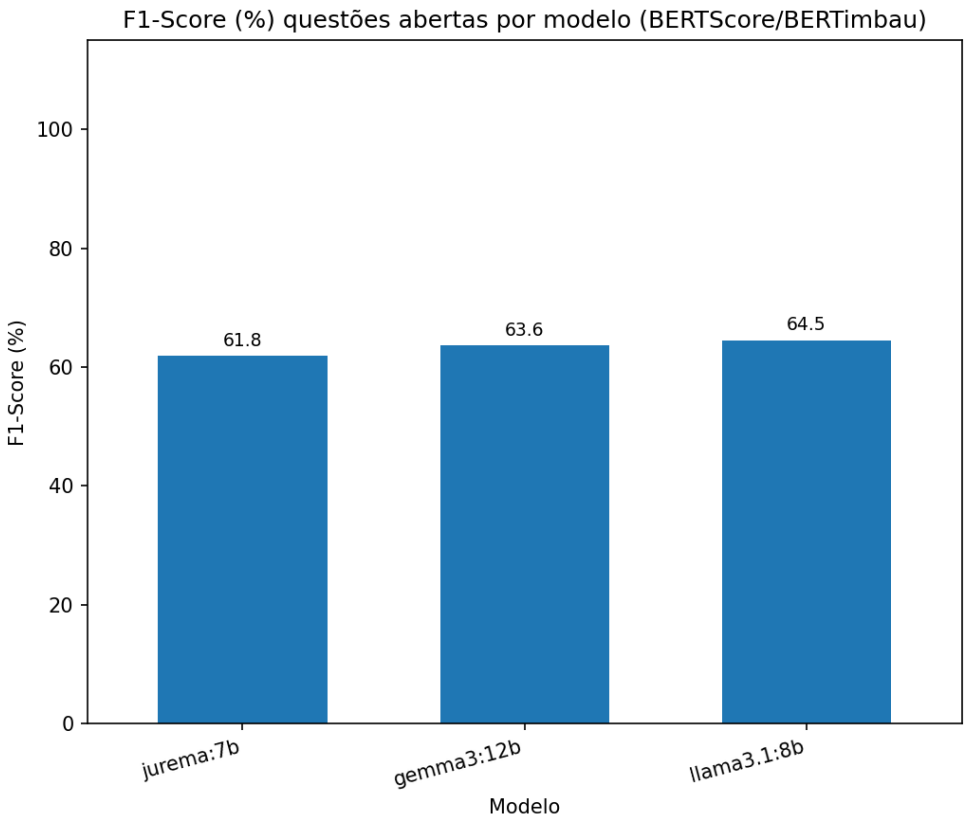
F1-Score (%) questões abertas por modelo (BERTScore/BERTimbau)
F1-Score (%)
0
20
40
60
80
100
61.8
63.6
64.5
jurema:7b
gemma3:12b
llama3.1:8b
Modelo

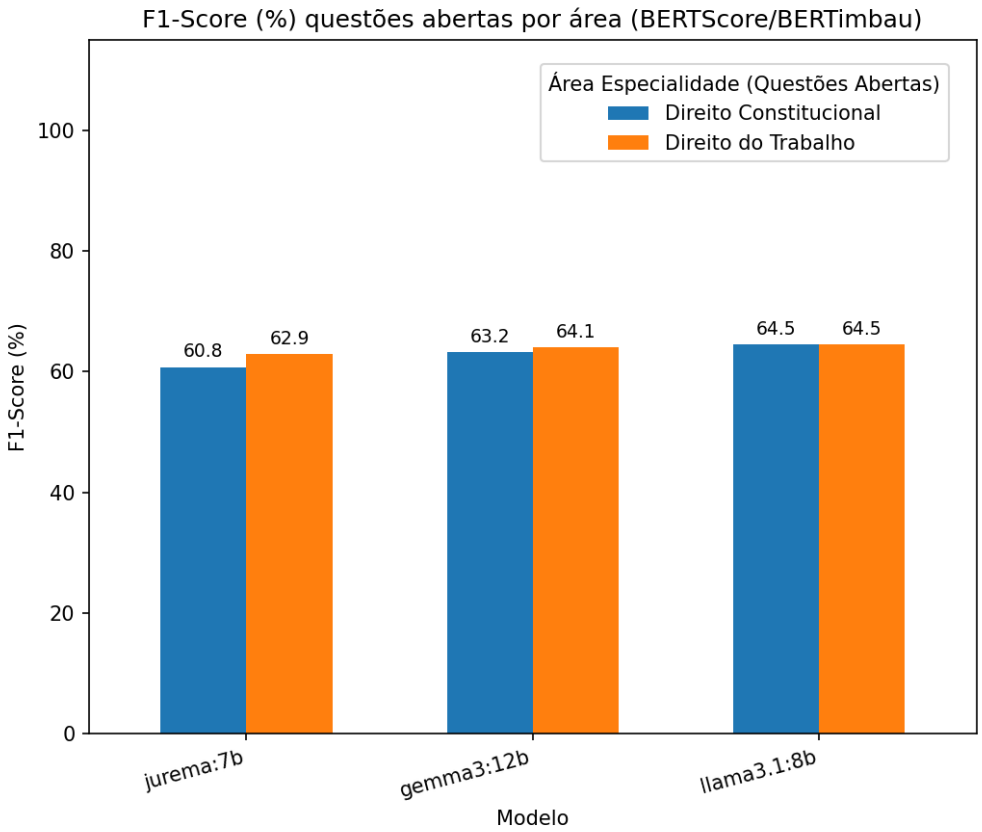
F1-Score (%) questões abertas por área (BERTScore/BERTimbau)
Área Especialidade (Questões Abertas)
Direito Constitucional
Direito do Trabalho
F1-Score (%)
0
20
40
60
80
100
60.8
62.9
63.2
64.1
64.5
64.5
jurema:7b
gemma3:12b
llama3.1:8b
Modelo

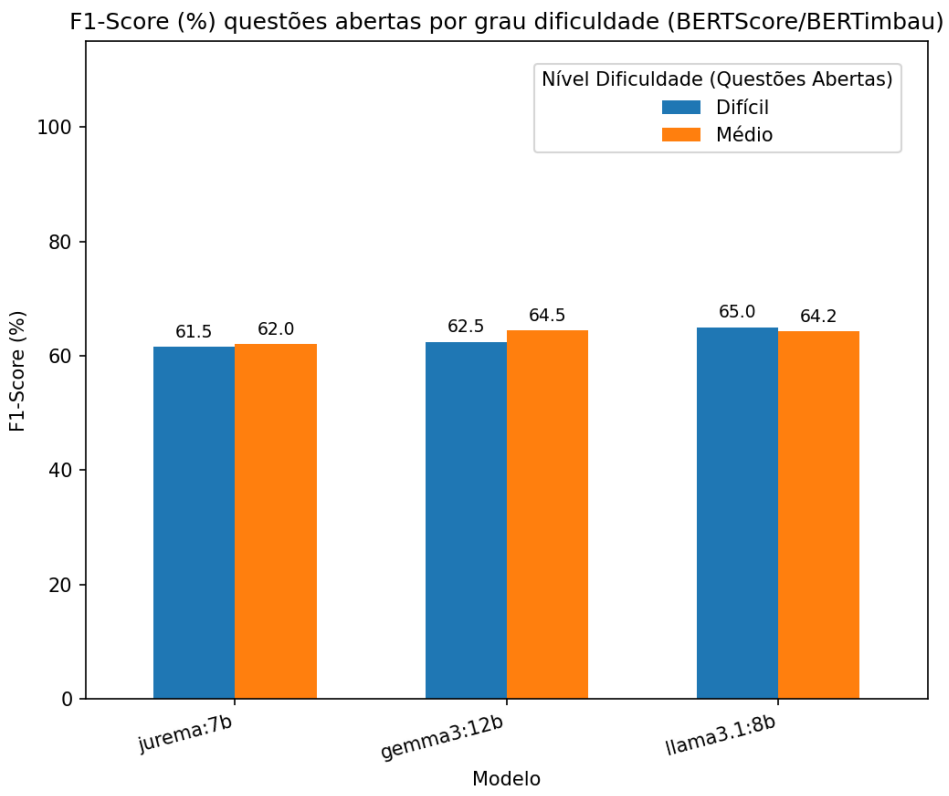

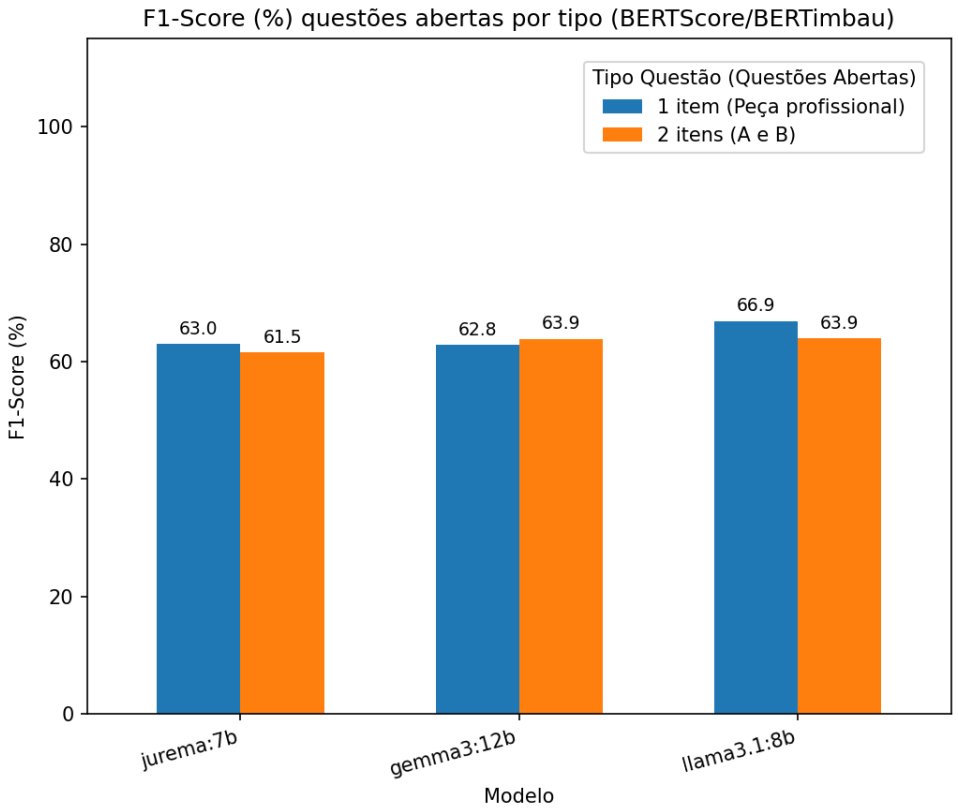

Observações

- O BERTScore não substitui a correção analítica oficial da OAB.
- As respostas foram coletadas com temperatura 0 para reduzir variabilidade.
- Os valores detalhados de registro são exibidos exatamente como constam no CSV consolidado.

Resultado Questões Objetivas

Foram 123 questões objetivas dos 16º e 17º Exames da OAB de 2015, avaliadas por acurácia da alternativa correta. Abaixo encontram-se as tabelas e gráficos dos resultados.

Melhor modelo
gemma3:12b
Acurácia: 55.3%
Questões avaliadas
123
16º e 17º Exame da OAB
Métrica principal
Acurácia
Comparação direta com o gabarito oficial

Tabelas – Questões Objetivas

Resumo geral

modelo_display	total	acertos	acuracia
gemma3:12b	123	68	55.3
jurema:7b	123	40	32.5
llama3.1:8b	123	60	48.8

Melhores áreas de especialidade por modelo

Modelo	Área Especialidade	Acurácia (%)
gemma3:12b	Filosofia do Direito	100.0
gemma3:12b	Direitos Humanos	80.0
gemma3:12b	Estatuto da Criança e do Adolescente	75.0
gemma3:12b	Direito Ambiental	75.0
gemma3:12b	Direito do Consumidor	75.0
jurema:7b	Direito Administrativo	58.3
jurema:7b	Ética Profissional	50.0
jurema:7b	Direito Processual Penal	40.0
jurema:7b	Direito Processual do Trabalho	40.0
jurema:7b	Direitos Humanos	40.0
llama3.1:8b	Estatuto da Criança e do Adolescente	75.0
llama3.1:8b	Filosofia do Direito	66.7
llama3.1:8b	Direito Internacional	66.7

Modelo	Área Especialidade	Acurácia (%)
llama3.1:8b	Direito Processual Penal	60.0
llama3.1:8b	Direito Administrativo	58.3

Acurácia por nível de dificuldade

Modelo	Nível Dificuldade	Acurácia (%)
gemma3:12b	Difícil	44.4
gemma3:12b	Fácil	61.1
gemma3:12b	Médio	56.3
jurema:7b	Difícil	27.8
jurema:7b	Fácil	27.8
jurema:7b	Médio	34.5
llama3.1:8b	Difícil	55.6
llama3.1:8b	Fácil	61.1
llama3.1:8b	Médio	44.8

Gráficos - Questões objetivas

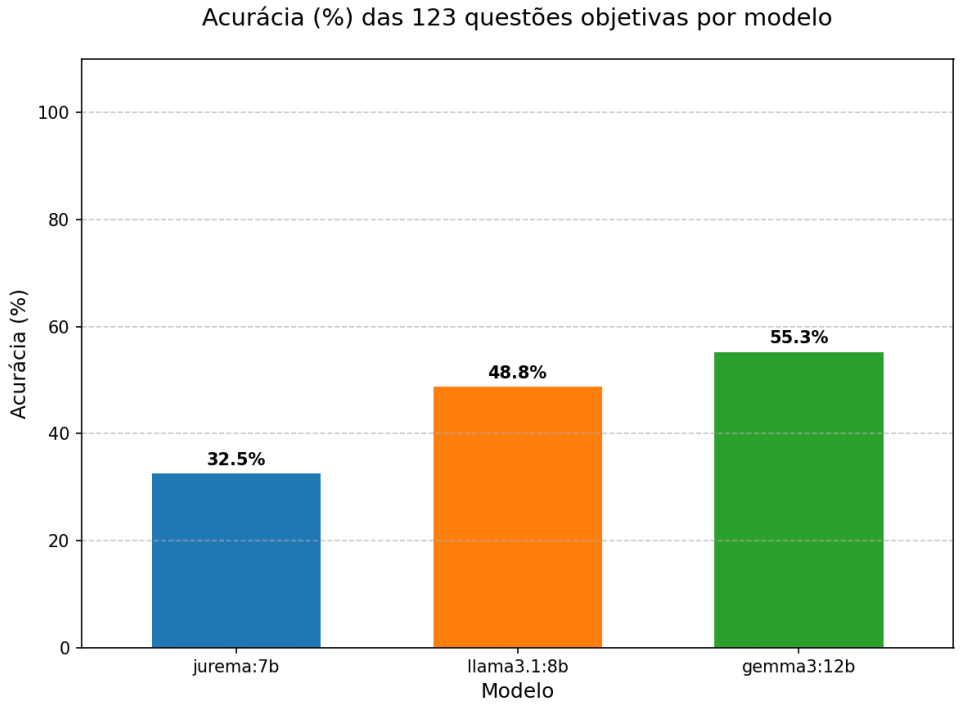

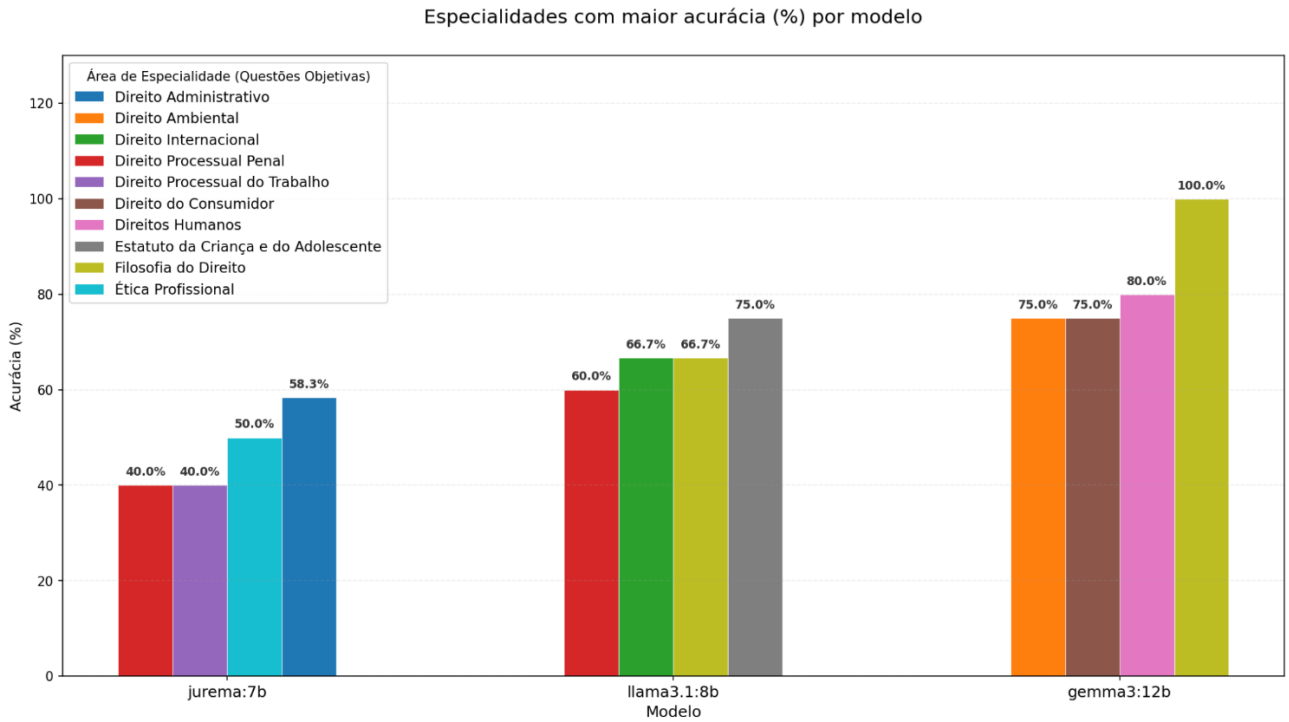
Especialidades com maior acurácia (%) por modelo
Área de Especialidade (Questões Objetivas)
Direito Administrativo
Direito Ambiental
Direito Internacional
Direito Processual Penal
Direito Processual do Trabalho
Direito do Consumidor
Direitos Humanos
Estatuto da Criança e do Adolescente
Filosofia do Direito
Ética Profissional
Acurácia (%)
0
20
40
60
80
100
120
40.0%
40.0%
50.0%
58.3%
60.0%
66.7%
66.7%
75.0%
75.0%
75.0%
80.0%
100.0%
jurema:7b
llama3.1:8b
gemma3:12b
Modelo

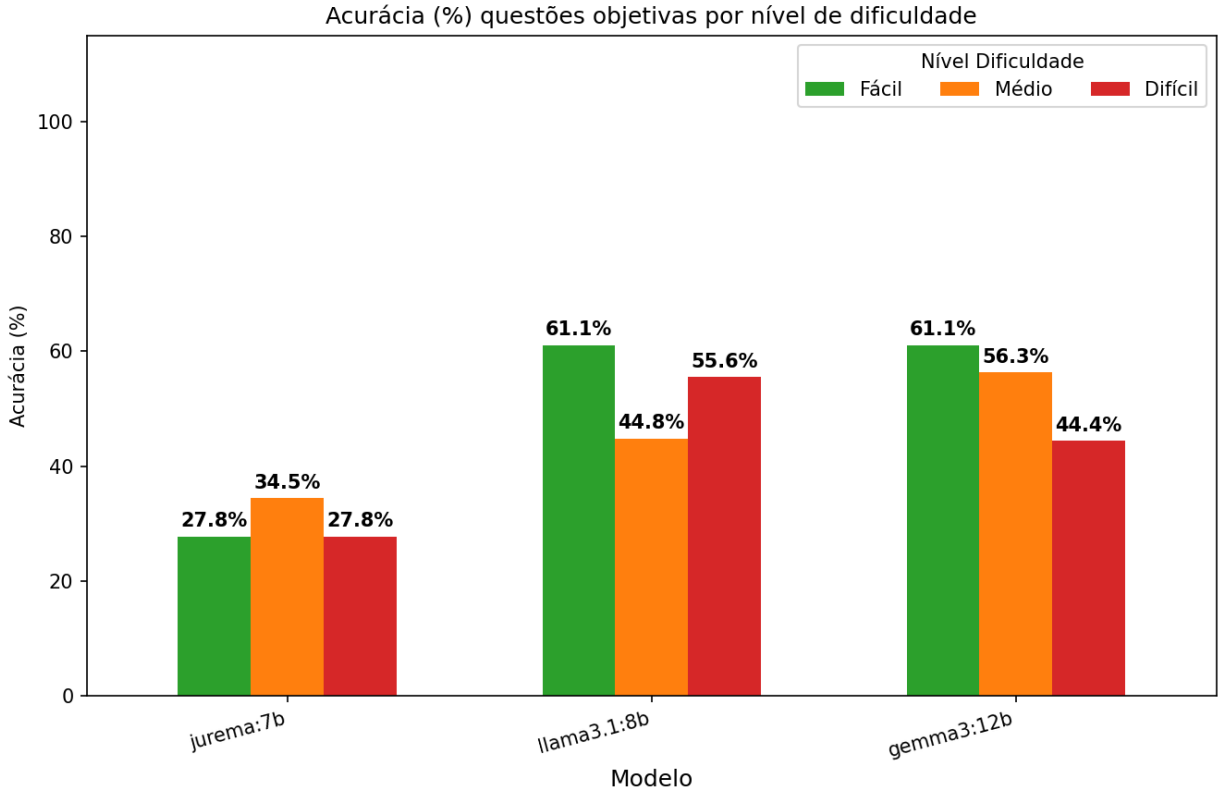
Acurácia (%) questões objetivas por nível de dificuldade
Nível Dificuldade
Fácil
Médio
Difícil
Acurácia (%)
0
20
40
60
80
100
27.8%
34.5%
27.8%
61.1%
44.8%
55.6%
61.1%
56.3%
44.4%
jurema:7b
llama3.1:8b
gemma3:12b
Modelo

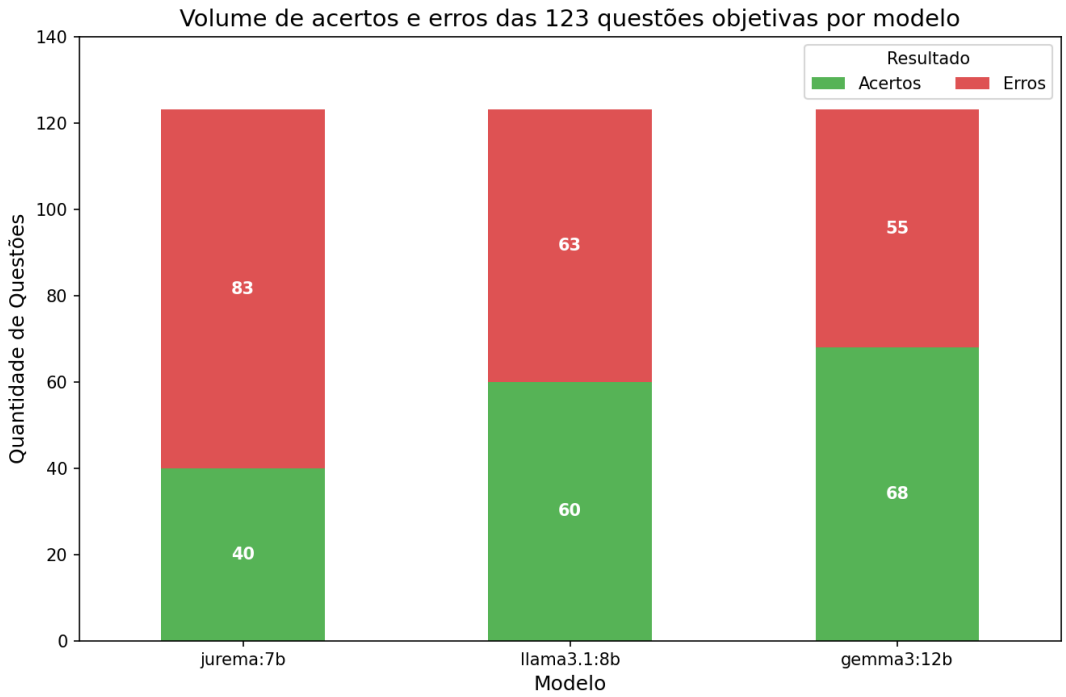

Observações

- As respostas objetivas foram coletadas via Ollama API com format JSON e temperatura 0.
- Os registros exibidos no formulário são somente leitura, para navegação e conferência.

Conclusões

Experimentos

Questões abertas (F1 Score)

- **BERTimbau Large atribuiu notas maiores do que o mBERT** para esse cenário em português jurídico. Isso sugere que esse avaliador especializado em português brasileiro captou melhor a similaridade semântica do que o modelo multilíngue.
- **O llama3.1:8b foi o melhor modelo nas questões abertas**, com 64,5% de F1-Score pelo BERTimbau Large.
- Gemma3:12b (63,6%)ficou muito próximo e o **Jurema:7b (61,8%), apesar de treinado no domínio jurídico brasileiro**, ficou em última colocação
- Considerando que, de acordo com o edital da OAB, no qual para a Nota na Prova Prático-Profissional (NPPP), numa escala de 0,00 (zero) a 10,00 (dez) pontos, será considerado aprovado o examinando que obtiver NPPP igual ou superior a 6,00 (seis) pontos, Nesse caso, **os 3 modelos seriam aprovados no exame de questões abertas**. Porém, **o gemma seria vencedor** por ter sido o único aprovado também na prova objetiva.

Questões objetivas (Acurácia)

- **O melhor modelo para questões objetivas foi o gemma3:12b**, com 68 acertos em 123 questões (55,28% de acurácia).
- **O jurema:7b foi o pior, também nas questões objetivas**, com apenas 40 acertos. A especialização temática do modelo não garantiu melhor acurácia.

- **Considerando que** a nota para habilitação à prova prático-profissional, isto é, **para passar para a segunda fase do certame é necessário o mínimo de 50% de acertos** nas questões objetivas, conforme edital da OAB, **apenas o gemma3:12b seria aprovado**.

Síntese

- **Modelo aprovado em ambas as fase do exame OAB:** gemma3:12b.
- **Questões abertas:** melhor modelo = llama3.1:8b.
- **Questões objetivas:** melhor modelo = gemma3:12b.
- **Jurema:7b não venceu em nenhum dos dois cenários. Esse talvez tenha sido o melhor achado, isto é, a maior surpresa desses dois experimentos.**

Arquivos disponíveis para consulta

Repositório

https://github.com/pamaralifs/atividade1_taessi/tree/main/files

Site Relatório (Github Pages)

https://pamaralifs.github.io/atividade1_taessi/#visualizadores

Vídeo Paulo_equipe_04_apresentacao_09-04-2026_02-23

https://www.vidline.com/share/V02WHO34G6/a1f63c7d913ddae74c079450eba8ac35

Paulo do Amaral Costa (Equipe 4)